



CHALLENGE FIAP × FORZY

Processamento de Linguagem Natural

Sprint 2

Visualização Operacional e Representação do Ativo

*Representação vetorial, consulta semântica
e geração de linguagem natural sobre o corpus de motores elétricos*

Equipe

Integrante	RM
Lucca Phelipe Masini	564121
Luiz Henrique Poss	562177
Felipe Stefani Honorato	563380
Igor Paixão Sarak	563726
Bernardo Braga Perobeli	562468

FIAP — Inteligência Artificial — 3º Semestre • maio/2026

Pasta da entrega no Drive:

drive.google.com/drive/folders/1y4Zx58Z4nJwzvnpU7GIJIFZYMqQF_EYv

Sumário

1	Introdução	1
2	Representação Vetorial dos Atributos do Ativo	2
2.1	Modelo escolhido	2
2.2	Comparação de modelos	2
2.3	Composição do texto de <i>embedding</i>	3
2.4	Indexação com FAISS	3
2.5	Dois índices complementares	4
3	Módulo de Consulta Semântica	4
3.1	Pipeline de busca	4
3.2	Dicionário de sinônimos Operador → Técnico	4
3.3	Consulta estruturada (filtro + ranking)	4
3.4	Conjunto de consultas-teste	5
3.5	Métricas de recuperação	5
3.6	Comparativo com e sem expansão de sinônimos	6
3.7	Análise de erros	6
4	Enriquecimento Textual da Interface	7
4.1	Motivação	7
4.2	Estado operacional simulado	7
4.3	Templates parametrizados	7
4.4	Regras de composição automática	7
4.5	Princípios textuais	8
4.6	Marcadores disponíveis	8
4.7	Exemplo concreto	8
5	Integração com a Sprint 1	9
5.1	Reutilização do corpus	9
5.2	Continuidade visual e de nomenclatura	9
5.3	Continuidade de decisões	9
5.4	Decisão crítica D008	9
6	Resultados e Discussão	9
6.1	Síntese das métricas	9
6.2	Quais consultas tiveram melhor desempenho e por quê	10
6.3	Limitações conhecidas	10
7	Decisões Documentadas	10
8	Conclusão	10

8.1 Cobertura dos exemplos do enunciado	10
8.2 Próximos passos	10
A1 Lista completa das consultas-teste	12
A2 Templates de NLG	12
A3 Dicionário de sinônimos	13
A4 Estrutura de arquivos da entrega	14

1 Introdução

A Forzy desenvolve um *digital twin* de motores elétricos industriais: uma réplica digital viva de cada ativo, que reúne dados de placa, manuais técnicos, cadastro de engenharia e leituras de operação para representar, em tempo real, o estado de cada máquina. O objetivo do produto é antecipar problemas em vez de reagir a eles. Hoje, a maior parte das plantas ainda detecta falhas em motores apenas *depois* que elas acontecem. Nesse momento a parada já interrompeu a produção, a manutenção ficou mais cara e, em alguns casos, a segurança foi comprometida. Um gêmeo digital que entende a linguagem da operação muda essa ordem: ele permite ler o ativo antes da falha.

Por que Processamento de Linguagem Natural

Boa parte do conhecimento sobre um motor está em *texto*: o manual do fabricante, a descrição do cadastro, a anotação do operador no log. Esse texto é heterogêneo. Cada equipe chama a mesma coisa por um nome diferente: o operador diz “motor quente”, o manual diz “sobretensão” e o cadastro registra “temperatura acima do limite de classe”. O Processamento de Linguagem Natural (PLN) entra para resolver três necessidades concretas do gêmeo digital: **(i)** padronizar o vocabulário entre as equipes, de modo que termos coloquiais e técnicos apontem para o mesmo conceito; **(ii)** permitir consultas em linguagem natural, para que qualquer pessoa pergunte “qual motor está mais quente na área 3?” sem conhecer o esquema do banco; e **(iii)** gerar relatórios operacionais automáticos, traduzindo números crus em descrições que o operador entende e sobre as quais consegue agir.

Continuidade da Sprint 1

A Sprint 1 construiu a base textual do gêmeo digital. Foi montado um corpus de 10 documentos sobre 3 motores (uma bomba WEG de 4 kW, MOT-PROD-001; um motor Siemens de 7,5 kW, MOT-UTIL-003; e um compressor ABB de 30 kW, MOT-COMP-007), distribuídos em quatro fontes: placa, manual, cadastro e log. Um *pipeline* de pré-processamento normalizou abreviações, unidades e nomes de fabricantes, e materializou tudo em um JSON estruturado (`corpus_sprint1_v1.0.0.json`), com campos de texto original, texto normalizado e *tokens* lematizados. É sobre essa base que a Sprint 2 trabalha.

Objetivos da Sprint 2

Este relatório documenta a transformação do corpus textual em um sistema de recuperação e descrição semântica do ativo. Os objetivos específicos são:

- representar os atributos de cada motor como vetores densos (*embeddings*) multilíngues, indexados em FAISS para busca por similaridade;
- implementar um módulo de consulta semântica que entenda sinônimos entre o vocabulário do operador e o do técnico, e que resolva consultas compostas (filtro + ranking);
- gerar descrições em linguagem natural (*NLG*) do estado operacional dos motores, voltadas à interface do operador;
- avaliar a recuperação com métricas objetivas (*Precision*, *Recall*, *F1* e *MRR*) e analisar os erros remanescentes;
- preservar a continuidade técnica e visual com a Sprint 1.

As seções a seguir tratam, nessa ordem, da representação vetorial (Seção 2), do módulo de consulta (Seção 3), do enriquecimento textual (Seção 4) e da integração com a Sprint 1 (Seção 5), encerrando com resultados (Seção 6), decisões documentadas (Seção 7) e conclusão (Seção 8).

2 Representação Vetorial dos Atributos do Ativo

Busca por palavra-chave não basta para o gêmeo digital. “Motor quente” não casa com “sobretensão” em uma busca lexical, e o operador não pode ser obrigado a adivinhar o vocabulário do manual. A solução é representar cada documento como um vetor denso em um espaço onde a proximidade geométrica reflete proximidade de significado. Esta seção justifica o modelo de *embeddings* escolhido, a composição do texto vetorizado e a estrutura de indexação em FAISS.

2.1 Modelo escolhido

Adotou-se o `paraphrase-multilingual-MiniLM-L12-v2`, da biblioteca *Sentence-Transformers*: 384 dimensões, cerca de 118 MB, suporte a aproximadamente 50 idiomas e treinamento orientado à identificação de paráfrases. A escolha leva em conta dois fatores: o idioma do corpus e o domínio industrial.

2.1.1 Justificativa frente ao idioma do corpus

O corpus é majoritariamente em português ($\approx 85\%$), mas contém trechos em inglês ($\approx 15\%$), originados dos manuais Siemens e ABB. Um modelo monolíngue obrigaria a rotear cada documento por idioma e a manter índices separados, fragmentando a busca. O modelo multilíngue escolhido produz *embeddings* com alinhamento *cross-lingual*: a frase em português “temperatura elevada” e a frase em inglês “high temperature” caem próximas no mesmo espaço vetorial. Isso elimina o roteamento por idioma e permite que uma consulta em português recupere um trecho de manual em inglês. A alternativa monolíngue mais forte para o português, o BERTimbau, foi descartada por dois motivos: não cobre o inglês presente no corpus e, por ser um modelo de linguagem mascarada, não foi ajustado para *retrieval*, e seus vetores de sentença, sem *fine-tuning*, são fracos para medir similaridade semântica.

2.1.2 Justificativa frente ao domínio industrial

O treinamento em identificação de paráfrases está diretamente alinhado ao caso de uso: o sistema precisa reconhecer que “motor quente” e “sobretensão” dizem a mesma coisa, e paráfrase é exatamente a tarefa de decidir se dois enunciados são equivalentes. A limitação conhecida é o vocabulário muito específico do domínio: designações como 6308-2Z (rolamento), IE3 (classe de eficiência, IEC 60034-30) ou IP55 (grau de proteção, IEC 60034-5) não fazem parte do treinamento do modelo e tendem a ser tratadas como *tokens* pouco informativos. Essa limitação é mitigada em duas frentes: pela normalização da Sprint 1, que expande e padroniza essas designações antes da vetorização, e pelo dicionário de sinônimos da Seção 3, que aproxima o vocabulário do operador do vocabulário técnico. Em produção, o caminho indicado é o *fine-tuning* do modelo sobre o corpus real da Forzy, ensinando-o explicitamente o vocabulário de motores.

2.2 Comparação de modelos

A Tabela 1 resume a avaliação de cinco alternativas frente aos dois fatores. A decisão privilegia cobertura multilíngue, objetivo de treino voltado a similaridade e tamanho compatível com execução em ambiente acadêmico (Colab).

Tabela 1. Modelos de *embedding* avaliados.

Modelo	Dim.	Idiomas	Tam.	Decisão
all-MiniLM-L6-v2	384	EN	80 MB	Descartado: monolíngue inglês, não cobre PT.
BERTimbau (base)	768	PT	420 MB	Descartado: monolíngue PT e sem ajuste para <i>retrieval</i> .
paraphrase-multilingual-MiniLM-L12-v2	384	≈50	118 MB	Escolhido: multilíngue, foco em paráfrase, leve.
distiluse-base-multilingual-cased-v2	512	≈50	480 MB	Descartado: ≈4× maior, ganho marginal.
Modelos industriais específicos (PT)	—	PT	—	Inexistentes como opção <i>mainstream</i> .

2.3 Composição do texto de *embedding*

Cada documento é convertido em uma única *string* antes de ser vetorizado, no formato [FONTE] TAG <id>. <texto_normalizado>. Prefixar a fonte e a TAG preserva o contexto do campo: o modelo “sabe” que aquele texto vem de um manual ou de um log e a que equipamento pertence, o que melhora a separação entre documentos parecidos de máquinas diferentes.

```
[PLACA] MOT-PROD-001. Motor de inducao trifasico WEG W22 Plus 100L,
      380 V, 8.4 A, 4 kW, 1738 rpm, IP55, classe de eficiencia IE3.
[MANUAL] MOT-COMP-007. Three-phase induction motor, 30 kW, bearing
      6308-2Z, regreasing interval 4000 h, protection IP55.
```

A decisão de usar o **texto normalizado**, e não os *tokens* lematizados produzidos na Sprint 1, é deliberada (decisão D008). Modelos *transformer* foram treinados sobre texto natural e dependem de *subword tokenization* própria; alimentá-los com texto já lematizado e sem ordem natural degrada a qualidade do vetor. Os *tokens* lematizados continuam úteis para análise estatística e busca lexical de apoio, mas não são a entrada da camada vetorial.

2.4 Indexação com FAISS

Os vetores são indexados em FAISS com `IndexFlatIP` (produto interno) sobre vetores normalizados em L_2 . Com vetores unitários, o produto interno equivale à similaridade do cosseno, que é a métrica desejada para comparar significado independentemente da magnitude.

```
emb = model.encode(textos, normalize_embeddings=True).astype("float32")
index = faiss.IndexFlatIP(emb.shape[1]) # produto interno == cosseno (L2-norm)
index.add(emb)
D, I = index.search(query_emb, k)      # top-k por similaridade
```

`IndexFlatIP` faz busca exata (*brute force*). Para 10 documentos isso é instantâneo e dispensa estruturas aproximadas. O plano de migração acompanha a escala do corpus: `IndexHNSWFlat` (grafo navegável) a partir de ~10 mil documentos, quando a busca exata começa a pesar; e `IndexIVFPQ` (quantização de produto) acima de ~1 milhão, quando a memória passa a ser o gargalo. A interface de consulta permanece a mesma; só a estrutura interna muda.

2.5 Dois índices complementares

O sistema mantém dois índices para atender a dois casos de uso distintos (decisão D013). O **índice por documento** guarda os 10 vetores individuais e serve a perguntas granulares (“qual o intervalo de lubrificação do compressor?”), retornando o trecho exato. O **índice por equipamento** guarda 3 vetores, um por motor, obtidos pela média dos vetores dos documentos daquele equipamento, renormalizada em L_2 ; ele serve a perguntas sobre o ativo como um todo (“qual motor está em alerta?”), retornando a máquina e não um documento isolado. A agregação por média é simples e estável para corpora pequenos, e mantém o equipamento no mesmo espaço dos documentos.

3 Módulo de Consulta Semântica

O módulo de consulta recebe uma pergunta em linguagem natural e devolve os documentos ou equipamentos mais relevantes. Seu diferencial é tratar a distância entre a linguagem do operador e a do técnico, e resolver consultas que combinam filtro e ordenação.

3.1 Pipeline de busca

A busca segue três etapas: **expansão de sinônimos** (reescreve a consulta aproximando-a do vocabulário técnico) → **codificação multilíngue** (gera o vetor da consulta com o mesmo modelo dos documentos) → **busca FAISS top-k** (recupera os vizinhos mais próximos por cosseno). A simetria entre como o documento e a consulta são codificados é essencial: ambos passam pelo mesmo modelo, no mesmo espaço.

3.2 Dicionário de sinônimos Operador → Técnico

O dicionário reúne cerca de 25 mapeamentos do vocabulário coloquial para o técnico. Por exemplo: “quente” → “temperatura elevada sobretemperatura” e “área 3” → “planta 1 área de produção linha 3”. A aplicação é **aditiva**: o termo técnico é *concatenado* à consulta original, não a substitui. Isso preserva a intenção do usuário e apenas enriquece o sinal semântico, evitando que uma substituição equivocada descarte informação. O dicionário completo está no Anexo A3.

```
def expandir(consulta):
    extra = [tec for termo, tec in SINONIMOS.items()
              if termo in consulta.lower()]
    return consulta + (" " + " ".join(extra) if extra else "")
```

3.3 Consulta estruturada (filtro + ranking)

Algumas perguntas não são puramente semânticas. “Equipamento de 220 V com maior temperatura” (o segundo exemplo do enunciado) combina um *filtro* estruturado (tensão = 220 V) com um *critério de ordenação* (maior temperatura). Busca vetorial pura falha nesse caso: ela confunde o filtro com o tema e tende a ranquear pelo conjunto de palavras, não pela grandeza. O módulo `consulta_estruturada` trata esse padrão (decisão D014) em quatro passos:

1. **Extração de filtros** por expressão regular: identifica tensão e potência na consulta (ex. “220 V”, “30 kW”);

2. **Pré-filtragem** dos equipamentos do corpus que satisfazem o filtro;
3. **Deteção do critério de ranking** (ex. “maior temperatura”) e ordenação dos equipamentos pré-filtrados pelo valor correspondente no estado operacional;
4. **Fallback**: se nenhum filtro estruturado é detectado, a consulta recai na busca semântica restrita ao subconjunto pertinente.

No exemplo, o regex extrai 220 V, pré-filtra os equipamentos de 220 V (apenas o MOT-UTIL-003), detecta “maior temperatura” e ordena pelo campo de temperatura do estado operacional, retornando corretamente o motor Siemens, que está em alerta térmico.

3.4 Conjunto de consultas-teste

A avaliação usa 14 consultas-teste construídas manualmente, cada uma com *ground truth* explícito (os documentos/equipamentos esperados). O conjunto inclui os dois exemplos literais do enunciado e cobre sete categorias de intenção: localização, aplicação, estado/alarme, especificação, fabricante, manutenção e filtro+ranking. A lista completa, com o gabarito de cada consulta, está no Anexo A1.

3.5 Métricas de recuperação

Avaliaram-se *Precision*, *Recall*, *F1* e *MRR* (*Mean Reciprocal Rank*) em $k = 1, 3, 5$. *Precision@k* mede a fração de relevantes entre os k primeiros; *Recall@k*, a fração dos relevantes do gabarito que aparece no top- k ; *F1* é a média harmônica das duas; e *MRR* mede a posição do primeiro acerto (quão alto, na lista, está o primeiro resultado certo). A Tabela 2 mostra o *Reciprocal Rank* por consulta, com e sem expansão de sinônimos; a Tabela 3 apresenta as métricas agregadas.

Tabela 2. *Reciprocal Rank* por consulta (▼ indica $RR < 0,5$ mesmo com sinônimos).

Consulta	Categoria	RR sem	RR com
”motor da área 3”	Localização	0,33	1,00
”equipamentos na planta 1”	Localização	1,00	1,00
”bomba”	Aplicação	1,00	1,00
”compressor”	Aplicação	1,00	1,00
”motor quente”	Estado/alarme	0,50	1,00
”equipamento em alerta”	Estado/alarme	0,33	1,00
”motor 30 kW”	Especificação	1,00	1,00
”motor IP55”	Especificação	0,25	0,33 ▼
”motores WEG”	Fabricante	1,00	1,00
”equipamento Siemens”	Fabricante	1,00	1,00
”rolamento 6308-2Z”	Manutenção	0,50	1,00
”intervalo de lubrificação”	Manutenção	0,20	0,25 ▼
”equip. 220 V c/ maior temperatura”	Filtro+ranking	0,33	1,00
”motor de maior potência”	Filtro+ranking	0,50	1,00

Tabela 3. Métricas agregadas **com** expansão de sinônimos (14 consultas).

Métrica	k = 1	k = 3	k = 5
P	0,86	0,74	0,56
R	0,27	0,70	0,88
F1	0,41	0,71	0,67
MRR	0,86	0,88	0,90

O padrão das métricas é o esperado para recuperação. A *Precision* cai com k crescente ($0,86 \rightarrow 0,74 \rightarrow 0,56$), porque resultados adicionais incluem itens menos relevantes; o *Recall* sobe ($0,27 \rightarrow 0,70 \rightarrow 0,88$), porque mais relevantes são capturados; o *F1* é máximo em $k = 3$ (0,71), o melhor equilíbrio entre os dois. O *MRR* alto e estável ($\approx 0,90$) indica que, quando há acerto, ele costuma aparecer já na primeira posição, que é o comportamento desejável para uma interface de consulta.

3.6 Comparativo com e sem expansão de sinônimos

A Tabela 4 isola o efeito do dicionário operador $\rightarrow$ técnico. O ganho é expressivo: a *Precision@1* salta de 0,43 para 0,86 e o *MRR* de 0,64 para 0,90. O efeito concentra-se exatamente onde se esperava: consultas com vocabulário coloquial ou de localização (“motor da área 3”, “equipamento em alerta”, “motor quente”), que sem o dicionário não casavam com o vocabulário técnico dos documentos. Consultas já técnicas (“motor 30 kW”, “motores WEG”) não mudam, confirmando que a expansão aditiva não prejudica o que já funcionava.

Tabela 4. Impacto da expansão de sinônimos sobre as métricas agregadas.

Configuração	P@1	F1@3	MRR
Sem expansão	0,43	0,45	0,64
Com expansão	0,86	0,71	0,90
Ganho absoluto	+0,43	+0,26	+0,26

3.7 Análise de erros

Mesmo com sinônimos, duas consultas mantêm *Reciprocal Rank* abaixo de 0,5 (“motor IP55” com 0,33 e “intervalo de lubrificação” com 0,25), e a consulta composta de filtro+ranking falha quando resolvida apenas por via semântica. Classificam-se as causas em cinco padrões recorrentes:

1. **Queries compostas.** “Equipamento de 220 V com maior temperatura” tem $RR \approx 0,33$ na via puramente semântica (o modelo mistura o filtro de tensão com o tema). O módulo `consulta_estruturada` eleva esse caso a $RR = 1,0$, o que é a justificativa empírica da decisão D014.
2. **Vocabulário coloquial fora do dicionário.** Termos não mapeados (ex. “motor chiando”) dependem só da similaridade do *embedding* e ranqueiam mais abaixo; a correção é ampliar o dicionário via *data flywheel* (Seção 8).
3. **Sobreposição lexical entre documentos.** “Motor IP55” atinge $RR = 0,33$ porque IP55 aparece em placas de mais de um motor, com texto de boilerplate semelhante; o modelo não distingue qual equipamento é o alvo.

4. **Termos em inglês sem cognato em português.** “Intervalo de lubrificação” ($RR = 0,25$) precisa casar com os manuais em inglês, que usam *regreasing interval*; sem o cognato direto, o alinhamento *cross-lingual* perde força.
5. **Paráfrase indireta.** A mesma consulta sofre de paráfrase indireta: o conceito “intervalo de lubrificação” aparece no manual como “reengraxar a cada 4.000 h”, sem repetir o termo, exigindo inferência que o modelo generalista nem sempre faz.

Os cinco padrões convergem para a mesma recomendação: normalização mais rica na ingestão e *fine-tuning* sobre o corpus real reduziriam os erros de vocabulário específico e de paráfrase, enquanto o roteamento estruturado já resolve as consultas compostas.

4 Enriquecimento Textual da Interface

4.1 Motivação

O operador não lê números crus do SCADA. “T=92” em uma tela não diz se o motor está bem, em risco ou perto de parar. O enriquecimento textual traduz a leitura em uma descrição contextualizada: identifica o ativo, compara a leitura com o limite da própria máquina e recomenda uma ação quando necessário. É a camada que transforma dado em informação acionável.

4.2 Estado operacional simulado

Para a Sprint 2, o estado operacional dos três motores foi simulado de forma coerente com o histórico da Sprint 1, conforme a Tabela 5. O MOT-UTIL-003 aparece em alerta térmico (recuperando-se do alarme registrado na sprint anterior), enquanto os demais operam em regime normal.

Tabela 5. Estado operacional simulado dos três ativos.

Equipamento	Status	Observação
MOT-PROD-001 (WEG, 4 kW)	normal	Bomba operando dentro dos parâmetros.
MOT-UTIL-003 (Siemens, 7,5 kW)	alerta_temperatura	Recuperando do alarme da Sprint 1; 220 V.
MOT-COMP-007 (ABB, 30 kW)	normal	Compressor operando dentro dos parâmetros.

4.3 Templates parametrizados

Foram definidos sete *templates* de mensagem, um por situação operacional: `normal`, `alerta_temperatura`, `alerta_vibracao`, `critico_temperatura`, `critico_vibracao`, `desligado` e `resumo_curto`. Cada *template* é uma *string* com marcadores que são preenchidos a partir do cadastro e da leitura do motor. O texto completo dos sete está no Anexo A2.

4.4 Regras de composição automática

A função `determinar_status` escolhe o *template* a partir da leitura, comparada aos limites do **próprio equipamento**, não a limites globais (decisão D012). A ordem de verificação prioriza os estados mais graves:

```
def determinar_status(eq, leitura):
    pct_temp = leitura.temperatura_c / eq.temp_max_c
    pct_vib = leitura.vibracao_mms / eq.vib_max_mms
    if not leitura.energizado: return "desligado"
    if pct_temp > 1.00: return "critico_temperatura"
    if pct_vib > 1.00: return "critico_vibracao"
    if pct_temp > 0.90: return "alerta_temperatura"
    if pct_vib > 0.85: return "alerta_vibracao"
    return "normal"
```

Os limiares (90% e 100% do limite) criam uma faixa de alerta antes do estado crítico, dando margem para ação preventiva. Os limites de vibração derivam das zonas de severidade da norma ISO 10816 (em mm/s), e os de temperatura, da classe de isolamento e do regime de serviço definidos pela IEC 60034-1; por isso são específicos de cada máquina.

4.5 Princípios textuais

A redação das mensagens segue seis princípios:

1. **TAG sempre presente** — toda mensagem começa identificando o ativo pela TAG;
2. **identidade contextual entre parênteses** — fabricante, modelo e localização logo após a TAG, para situar o operador;
3. **unidades padronizadas** — V, A, RPM, mm/s e °C, sempre explícitas;
4. **hierarquia visual** — prefixos [ALERTA], [CRÍTICO] e [DESLIGADO] aparecem apenas em estados não-normais, destacando o que exige atenção;
5. **recomendação acionável** — toda mensagem não-normal termina com uma ação concreta (“verificar ventilação”, “inspecionar mancais”);
6. **formato PT-BR para números** — separador de milhar com ponto e decimal com vírgula (ex. 1.738 RPM), conforme o exemplo do enunciado.

4.6 Marcadores disponíveis

Os *templates* dispõem do seguinte conjunto de marcadores, agrupados por natureza:

```
Identificacao : {tag} {fabricante} {modelo} {localizacao} {aplicacao}
Leituras      : {tensao_v} {corrente_a} {rpm} {vibracao_mms} {temperatura_c}
Limites       : {vib_max_mms} {temp_max_c} {corr_nom_a}
Derivados     : {pct_vib} {pct_temp} {rpm_fmt} {horas_op_fmt}
Contexto      : {ultima_leitura} {causa}
```

4.7 Exemplo concreto

Aplicando o *template* `normal` ao MOT-PROD-001, com sua leitura simulada, o sistema gera a mensagem renderizada abaixo. Note a TAG, a identidade entre parênteses, as unidades e o número no formato PT-BR (1.738 RPM):

```
Motor MOT-PROD-001 (WEG W22 Plus 100L, Planta 1 - Area de Producao -
```

```
Linha 3) operando dentro dos parametros normais. Ultima leitura  
(2025-05-27 14:32:00): 380 V, 8.4 A, 1.738 RPM, vibracao 1,8 mm/s,  
temperatura 62 C. Todos os indicadores abaixo dos limites de alarme.
```

5 Integração com a Sprint 1

5.1 Reutilização do corpus

A Sprint 2 consome diretamente o artefato da Sprint 1: o `corpus_sprint1_v1.0.0.json` é carregado como entrada da camada de *embeddings*, sem reprocessar o texto. Para garantir execução autônoma no Colab (mesmo quando o arquivo não está montado), o notebook inclui um *fallback* com uma cópia mínima do corpus embutida no código. A integração, portanto, é por contrato de dados: a Sprint 2 depende apenas do formato JSON acordado, não da execução da Sprint 1.

5.2 Continuidade visual e de nomenclatura

Mantêm-se a mesma equipe, a paleta institucional (verde #1D9E75 e roxo #534AB7) e a convenção de nomes de artefatos `{tipo}_sprint2_v{versao}.{ext}`, em paralelo à da Sprint 1. A consistência facilita rastrear, entre sprints, qual artefato gerou qual.

5.3 Continuidade de decisões

O registro de decisões da Sprint 1 (D001–D006) é estendido nesta sprint por nove novas decisões fundamentadas (D007–D015), consolidadas na Seção 7. Cada decisão da Sprint 2 referencia, quando pertinente, a decisão da Sprint 1 sobre a qual se apoia, preservando a rastreabilidade do raciocínio técnico ao longo do projeto.

5.4 Decisão crítica D008

A decisão mais sensível da integração é a D008: usar o **texto normalizado** da Sprint 1 como entrada da vetorização, e não os *tokens* lematizados. O motivo é técnico: modelos *transformer* esperam texto natural e aplicam sua própria tokenização em *subwords*; texto pré-lematizado e fora de ordem degrada o vetor. Os *tokens* lematizados não são descartados: permanecem úteis para análise estatística e para buscas lexicais de apoio. É um caso em que dois artefatos da Sprint 1 servem a finalidades distintas, e a Sprint 2 escolhe conscientemente o adequado a cada camada.

6 Resultados e Discussão

6.1 Síntese das métricas

A configuração final, com busca multilíngue, expansão de sinônimos e roteamento estruturado, alcançou *Precision@1* de 0,86, *F1@3* de 0,71 e *MRR* de 0,90 sobre as 14 consultas-teste (Tabela 3). Frente à *baseline* sem expansão de sinônimos, o ganho é de +0,43 em *Precision@1* e +0,26 em *MRR* (Tabela 4), atribuível ao dicionário operador → técnico.

6.2 Quais consultas tiveram melhor desempenho e por quê

As consultas de **fabricante**, **aplicação** e **especificação** atingiram $RR = 1,0$. A razão é o vocabulário distintivo e de baixa ambiguidade: “WEG”, “compressor” e “30 kW” identificam um único ativo no corpus, com forte sinal lexical e semântico. As consultas de **localização** e **estado/alarme** passaram a acertar na primeira posição *depois* da expansão de sinônimos, que aproximou “área 3” de “linha 3” e “quente” de “sobretensão”. As consultas **compostas** (filtro+ranking) acertaram graças ao módulo `consulta_estruturada`, que as resolve por filtragem e ordenação explícitas em vez de similaridade pura. O denominador comum dos acertos é a existência de um sinal não-ambíguo ligando a consulta ao alvo, seja ele lexical, semântico ou estrutural.

6.3 Limitações conhecidas

Três limitações delimitam o alcance dos resultados. **Corpus pequeno**: 10 documentos e 3 equipamentos tornam as métricas sensíveis a cada acerto ou erro individual, de modo que os números indicam tendência, não estatística robusta. **Modelo generalista**: o `paraphrase-multilingual-MiniLM-L12-v2` não conhece nativamente o vocabulário industrial (códigos de rolamento, classes IE/IP), o que explica os erros de vocabulário específico. **Estado operacional estático**: as leituras são simuladas e fixas, não um fluxo de dados em tempo real. A camada de NLG está pronta para receber *streaming*, mas ainda não foi conectada a ele.

7 Decisões Documentadas

A Tabela 6 consolida as nove decisões técnicas da Sprint 2, em continuidade ao registro D001–D006 da Sprint 1.

8 Conclusão

A Sprint 2 converteu o corpus textual da Sprint 1 em um sistema de recuperação e descrição semântica do ativo. A representação vetorial multilíngue, indexada em FAISS, mostrou-se adequada ao corpus bilíngue; o módulo de consulta, com expansão de sinônimos e roteamento estruturado, atingiu MRR de 0,90; e a camada de NLG traduz o estado operacional em mensagens acionáveis para o operador. A análise de erros isolou cinco causas recorrentes e ligou cada uma a uma melhoria concreta.

8.1 Cobertura dos exemplos do enunciado

Os dois exemplos literais do enunciado são atendidos por mecanismos distintos e complementares. “Motor da área 3” é resolvido pela **expansão de sinônimos**: o *Reciprocal Rank* dessa consulta sobe de 0,33 (sem dicionário) para 1,0 (com dicionário), ao mapear “área 3” para “planta 1 área de produção linha 3” e recuperar o MOT-PROD-001. “Equipamento de 220 V com maior temperatura” é resolvido pela **consulta estruturada**: o regex extrai o filtro de 220 V, pré-filtra o MOT-UTIL-003 e o ordena por temperatura, retornando-o com $RR = 1,0$. A busca puramente semântica, no mesmo caso, ficaria em $RR \approx 0,33$.

8.2 Próximos passos

- **Fine-tuning** do modelo de *embeddings* sobre o corpus real da Forzy, para internalizar o vocabulário industrial e reduzir os erros de termo específico;

Tabela 6. Decisões técnicas da Sprint 2 (D007–D015).

ID	Decisão	Justificativa
D007	Modelo paraphrase-multilingual-MiniLM-L12-v2	Cobre PT+EN com alinhamento <i>cross-lingual</i> ; foco em paráfrase; leve (118 MB).
D008	texto_normalizado como entrada (não lematizados)	<i>Transformers</i> preferem texto natural; lematizados ficam para análise estatística.
D009	Composição [FONTE] + TAG + texto	Preserva contexto do campo e separa documentos de máquinas distintas.
D010	IndexFlatIP com vetores L2-normalizados	Produto interno = cosseno; busca exata adequada ao corpus pequeno.
D011	Expansão de <i>query</i> por sinônimos (aditiva)	Aproxima vocabulário do operador do técnico sem descartar a intenção original.
D012	<i>Templates</i> NLG por limiares (90%/100%)	Faixa de alerta antes do crítico; limites por equipamento.
D013	Dois índices (documento + equipamento)	Atende consultas granulares e consultas sobre o ativo inteiro.
D014	consulta_estruturada para <i>queries</i> compostas	Filtro+ranking explícitos onde a busca semântica pura falha.
D015	Formato PT-BR para números nos <i>templates</i>	Padrão local de milhar/decimal (ex. 1.738 RPM).

- **migração para IndexHNSWFlat** quando o corpus escalar para dezenas de milhares de documentos, preservando a interface de consulta;
- **integração com o SCADA via webhook**, substituindo o estado simulado por leituras em tempo real na camada de NLG;
- **ampliação do dicionário de sinônimos via data flywheel**, capturando termos coloquiais reais das consultas em produção;
- **teste A/B** do impacto da expansão de *query* sobre a satisfação do operador, validando em campo o ganho observado em laboratório.

Anexo A1 — Lista completa das consultas-teste

A Tabela 8 lista as 14 consultas-teste com seu *ground truth*. Voltagens de referência: WEG 380 V, Siemens 220 V, ABB 440 V.

Tabela 8. Consultas-teste e gabarito.

#	Consulta	Categoria	Gabarito (alvo)
1	motor da área 3	Localização	MOT-PROD-001 (WEG)
2	equipamentos na planta 1	Localização	MOT-PROD-001 (WEG)
3	bomba	Aplicação	MOT-PROD-001 (WEG)
4	compressor	Aplicação	MOT-COMP-007 (ABB)
5	motor quente	Estado/alarme	MOT-UTIL-003 (Siemens)
6	equipamento em alerta	Estado/alarme	MOT-UTIL-003 (Siemens)
7	motor 30 kW	Especificação	MOT-COMP-007 (ABB)
8	motor IP55	Especificação	MOT-PROD-001 (WEG)
9	motores WEG	Fabricante	MOT-PROD-001 (WEG)
10	equipamento Siemens	Fabricante	MOT-UTIL-003 (Siemens)
11	rolamento 6308-2Z	Manutenção	MOT-COMP-007 (ABB)
12	intervalo de lubrificação	Manutenção	Manuais MOT-UTIL-003 e MOT-COMP-007
13	equipamento de 220 V com maior temperatura	Filtro+ranking	MOT-UTIL-003 (Siemens)
14	motor de maior potência	Filtro+ranking	MOT-COMP-007 (ABB)

Anexo A2 — Templates de NLG

Os sete *templates* completos. Marcadores entre chaves são preenchidos em tempo de geração; prefixos de severidade aparecem apenas em estados não-normais.

normal

```
Motor {tag} ({fabricante} {modelo}, {localizacao}) operando dentro dos
parametros normais. Ultima leitura ({ultima_leitura}): {tensao_v} V,
{corrente_a} A, {rpm_fmt} RPM, vibracao {vibracao_mms} mm/s, temperatura
{temperatura_c} C. Todos os indicadores abaixo dos limites de alarme.
```

alerta_temperatura

```
[ALERTA] Motor {tag} ({fabricante} {modelo}, {localizacao}) com
temperatura elevada: {temperatura_c} C ({pct_temp}% do limite de
{temp_max_c} C). Demais parametros normais. Recomendacao: verificar
ventilacao e carga; agendar inspecao termica.
```

alerta_vibracao

```
[ALERTA] Motor {tag} ({fabricante} {modelo}, {localizacao}) com vibracao
elevada: {vibracao_mms} mm/s ({pct_vib}% do limite de {vib_max_mms}
mm/s). Recomendacao: inspecionar alinhamento, fixacao e rolamentos.
```

critico_temperatura

```
[CRITICO] Motor {tag} ({fabricante} {modelo}, {localizacao}) em
sobretemperatura: {temperatura_c} C, acima do limite de {temp_max_c} C
({pct_temp}%). Risco de degradacao do isolamento. Recomendacao: reduzir
carga ou desligar e abrir manutencao corretiva imediata.
```

critico_vibracao

```
[CRITICO] Motor {tag} ({fabricante} {modelo}, {localizacao}) com vibracao
critica: {vibracao_mms} mm/s, acima do limite de {vib_max_mms} mm/s
({pct_vib}%). Risco de falha mecanica. Recomendacao: desligar e
inspecionar mancais e acoplamento.
```

desligado

```
[DESLIGADO] Motor {tag} ({fabricante} {modelo}, {localizacao}) fora de
operacao. Ultima leitura registrada em {ultima_leitura}. Sem leituras
ativas de corrente ou rotacao. {causa}
```

resumo_curto

```
{tag} - {fabricante} {modelo} - {localizacao}: {temperatura_c} C /
{vibracao_mms} mm/s / {rpm_fmt} RPM.
```

Anexo A3 — Dicionário de sinônimos

Mapeamento do vocabulário do operador para o vocabulário técnico, aplicado de forma aditiva (o termo técnico é concatenado à consulta).

Tabela 9. Dicionário operador → técnico.

Termo (operador)	Expansão técnica
quente	temperatura elevada sobretemperatura
esquentando	temperatura elevada aquecimento
fervendo	sobretemperatura crítica
frio	temperatura normal baixa temperatura
parado	desligado fora de operação
desligado	sem energia fora de operação
ligado	em operação energizado
barulho	ruído vibração elevada

Termo (operador)	Expansão técnica
tremendo	vibração elevada desbalanceamento
vibrando	vibração mm/s severidade
chiando	ruído de rolamento mancal
área 3	planta 1 área de produção linha 3
produção	planta 1 área de produção
utilidades	planta 2 utilidades
compressores	planta 3 casa de compressores
bomba	bombeamento bomba centrífuga
compressor	compressão ar comprimido
corrente alta	sobrecarga corrente elevada amperagem
girando rápido	rotação elevada RPM
rolamento	mancal rolamento esfera
mancal	rolamento apoio
lubrificação	reengraxe graxa intervalo de relubrificação
troca de óleo	lubrificação manutenção preventiva
revisão	manutenção preventiva inspeção
defeito	falha anomalia alarme
alarme	alerta evento crítico
cheiro de queimado	superaquecimento isolamento danificado

Anexo A4 — Estrutura de arquivos da entrega

```
entrega_sprint2/
|- notebook_sprint2.ipynb      # notebook executado (Drive)
|- corpus_sprint1_v1.0.0.json  # corpus reutilizado da Sprint 1
|- embeddings_sprint2_v1.0.0.npy # vetores 384-d (10 docs + 3 equip.)
|- index_doc_sprint2_v1.0.0.faiss # indice por documento
|- index_eq_sprint2_v1.0.0.faiss # indice por equipamento
|- sinonimos_sprint2_v1.0.0.json # dicionario operador -> tecnico
|- templates_sprint2_v1.0.0.json # 7 templates de NLG
|- metricas_sprint2_v1.0.0.csv  # P, R, F1, MRR por consulta
|- relatorio_sprint2_v1.0.0.pdf # este documento
```

Pasta da entrega (Drive): drive.google.com/drive/folders/1y4Zx58Z4nJwzvnpU7GIJIFZYMqQF_EYv